

Report Lab02 – Color Compression

AUGUST 7

Toán Ứng dụng và Thống Kê

Tác giả: Phạm Ngọc Thùy Trang – 18127022



PROJECT 01 – LAB02

THÔNG TIN CÁ NHÂN

Họ và tên: Phạm Ngọc Thùy Trang

MSSV: 18127022

Lớp: 18CLC1

Ý TƯỞNG THỰC HIỆN VÀ MÔ TẢ CÁC HÀM

Như ta đã biết, phân mảnh hình ảnh là một quá trình phân đoạn một bức ảnh kỹ thuật số thành nhiều vùng riêng biệt mà mỗi pixel (một tập các pixel hay còn gọi là superpixels) của nó có cùng thuộc tính với nhau. Bằng cách này ta có thể xử lý chỉ với những thành phần quan trọng của bức ảnh thay vì phải xử lý toàn bộ bức ảnh đó. Mục đích của bài toán này chính là phân dữ liệu thành các cụm (cluster) khác nhau sao cho dữ liệu trong cùng một cụm có tính chất giống nhau. Trong đó cụm là tập hợp các điểm ở gần nhau trong một không gian nào đó. Từ đó ta sẽ xác định một con số cụ thể k bất kỳ cho clusters (con số này sẽ đề cập đến số lượng centroid ta cần trong tập dữ liệu).

Thuật toán này được sử dụng khi ta có dữ liệu chưa được đánh dấu (dữ liệu mà chưa được gom nhóm hay phân loại). Nó sẽ giúp ta tìm ra những nhóm dựa trên sự tương đồng của dữ liệu với số lượng các nhóm được biểu diễn bởi con số $k_cluster$.

The diagram shows the objective function formula for K-means clustering: $J = \sum_{j=1}^k \sum_{i=1}^n \|x_i^{(j)} - c_j\|^2$. Annotations include: 'number of clusters' pointing to k , 'number of cases' pointing to n , 'case i ' pointing to $x_i^{(j)}$, 'centroid for cluster j ' pointing to c_j , 'objective function' pointing to J , and 'Distance function' pointing to the term $\|x_i^{(j)} - c_j\|^2$.

Pic Credit: saedsayad.com

Ý tưởng như sau:

1. Chọn số cluster k . Dữ liệu đầu vào là bức ảnh và số lượng cluster K cần tìm
2. Chọn K điểm bất kỳ làm các center (centroid) ban đầu
3. Phân mỗi điểm dữ liệu vào cluster có center gần nó nhất \rightarrow những điểm mà hình thành nên các K cluster
4. Nếu việc gán dữ liệu vào từng cluster ở bước trên không thay đổi gì so với vòng lặp trước nó thì ta dừng thuật toán. Dữ liệu đầu ra là bức ảnh sau khi đã được compress theo số lượng K cần tìm, các center M và label vector cho từng điểm dữ liệu Y , kích thước ảnh sau khi dùng thuật toán K-mean để compress (*không bắt buộc*)

5. Tính toán và cập nhật lại các center mới cho mỗi cluster bằng cách dùng trung bình cộng của tất cả các điểm dữ liệu đã được gán vào cluster đó ở bước 3
6. Quay lại bước 3

Theo như em tìm hiểu được thì bài toán này có liên quan đến hàm mất mát và bài toán tối ưu, cụ thể: Nếu ta coi center m_k là center (hoặc representative) của mỗi cluster và ước lượng tất cả các điểm được phân vào cluster này bởi m_k , thì một điểm dữ liệu x_i được phân vào cluster k sẽ bị sai số là $(x_i - m_k)$. Chúng ta mong muốn sai số này có trị tuyệt đối nhỏ nhất

Bên cạnh đó cũng không quên giảm số lượng màu của tấm ảnh về một số lượng màu chính để giảm kích thước lưu trữ.

Mô tả các hàm:

Vì trong code đã được chú thích rất kĩ nên ta sẽ đi vào những hàm/công việc chính:

Tên hàm/ Tên công việc	Mô tả
<pre>import matplotlib import numpy as np import numpy.matlib import random import PIL import os import warnings warnings.filterwarnings("ignore")</pre>	Import các thư viện cần thiết
<pre># Đọc hiển thị bức ảnh đầu vào image = PIL.Image.open(path image) matplotlib.pyplot.imshow(image) image = np.asarray(image)</pre>	Đọc và hiển thị bức ảnh đầu vào (dùng thư viện)
<pre>image_height = image.s hape[0] image_width = image.sh ape[1] image = image/255 img_1d = image.reshape (image.shape[0]*image. shape[1],3) print(img_1d.shape) print(img_1d)</pre>	<p>Lấy các thông tin của bức ảnh như lấy thông số dòng và thông số cột cũng như chuyển mỗi giá trị pixel về dạng $[0,1]$. Điều này sẽ giúp thuật toán k-means xử lý hiệu quả hơn.</p> <p>Ta có thể dùng các method từ thư viện để có được những thông tin này và dùng lệnh print để kiểm tra</p>

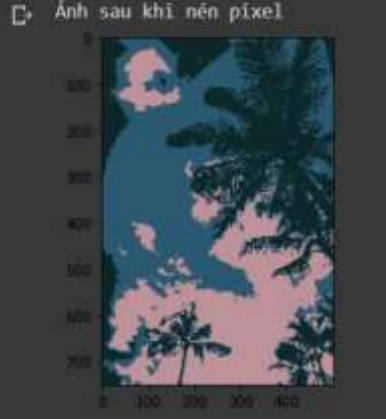


def closet_centroids(X,c)	<p>Hàm này được dùng để tìm các điểm giá trị pixel gần với mỗi giá trị centroids</p> <p>Để hiểu được công thức tìm các điểm giá trị pixel này, ta cần đọc trước và hiểu công thức hàm mất mát và bài toán tối ưu</p>
def compute_centroids (img_1d, idx, k_clusters)	Bằng cách truyền vào các tham số như thông số vòng lặp chạy, số k cluster và ảnh X sau khi tiền xử lý để tính toán các giá trị các centroids (các center)
def kmeans(img_1d, k_clusters, max_iter, init_centroids = 'random')	<p>Bằng cách truyền vào các tham số như thông số vòng lặp chạy, số k cluster, tổng số lần chạy của thuật toán kmeans trước khi kết thúc là max-iter, các giá trị center ban đầu được khởi tạo, ảnh X sau khi tiền xử lý để trả ra các centroid và các nhãn.</p> <p>Trong TH nếu ta khai báo init_centroids là radom thì hàm sẽ khởi tạo ngẫu nhiên các giá trị centroids, ngược lại sẽ tính toán dựa trên bức ảnh.</p> <p>Tuy nhiên để đảm bảo bài toán luôn chạy đúng thì ta nên chọn hàm tính toán có cơ sở. Vì nếu hàm random centroids không cho ra các giá trị phù hợp nằm gần các giá trị của bức ảnh, bài toán sẽ chạy không tốt.</p>
def init_centroids_func(img_1d, k_clusters)	Hàm này được dùng để khởi tạo giá trị centroid dựa trên tham số đầu vào là ảnh X và số lớp clusters K
def init_centroids_random_func(img_1d, k_clusters)	Hàm này cũng được dùng để khởi tạo giá trị centroid, tuy nhiên nó sẽ dùng hàm np.radom.rand để tạo ra giá trị trong khoảng từ 0 tới 1. Nói nôm na hàm này sẽ cho ra giá trị centroids có độ chính xác không cao bằng hàm def init_centroids_func(img_1d, k_clusters) trong TH các giá trị nó tạo ra không gần với các giá trị của bức ảnh.

HÌNH ẢNH KẾT QUẢ VỚI TỪNG SỐ LƯỢNG MÀU, K = {3,5,7}

Với đầu vào là một tấm ảnh bên dưới



Tương ứng với từng chỉ số $k_clusters$ ta có kết quả tương ứng như sau:

k_clusters	Hình ảnh đầu vào	Hình ảnh kết quả
3		
5		
7		

NHẬN XÉT KẾT QUẢ TRÊN

Mục đích của bài toán này chính là phân dữ liệu thành các cụm (cluster) khác nhau sao cho dữ liệu trong cùng một cụm có tính chất giống nhau. Trong đó cụm là tập hợp các điểm ở gần nhau trong một không gian nào đó. Từ đó ta sẽ xác định một con số cụ thể k bất kì cho clusters (con số này sẽ đề cập đến số lượng centroid ta cần trong tập dữ liệu và mỗi một điểm ảnh sau khi xử lý sẽ được biểu diễn bởi 1 số tương ứng với 1 cluster). Hay nói cách khác là ta phân mảnh dữ liệu đầu vào thành K -cluster hoặc những phân khác nhau dựa trên các K -centroids

Đó là lý do nếu ta có số $k_clusters$ càng nhiều thì ta thấy màu sắc càng gần với màu sắc của bức ảnh ban đầu hơn do thuật toán Kmeans đã phân loại nhiều cluster màu hơn, còn nếu càng ít thì màu sắc của nó càng xa với màu sắc thực tế hơn. Và sau khi compress thì ta thấy *chất lượng ảnh đã giảm đi nhiều*.

Chẳng hạn:

- **Với $k = 3$** thì thuật toán đã phân loại bức ảnh gốc của chúng ta thành **3 miền màu khác nhau**. Bức tranh lúc này do chỉ có 3 màu nên khá mờ và một số vật thể vẫn chưa rõ hình thù như bức tranh gốc, đặc biệt là vùng trời, ta có thể thấy hình thù của mây và cây, nhưng với mây thì nó chỉ có một sắc thái duy nhất.
- **Với $k = 5$** , thuật toán đã phân loại bức ảnh gốc của chúng ta thành **5 miền màu khác nhau**. Bức tranh lúc này đã rõ hơn lúc trước và ta cũng có thể thấy thêm nhiều sắc thái khác nhau của bầu trời và mây.
- **Với $k = 7$** , thuật toán đã phân loại bức ảnh gốc của chúng ta thành **7 miền màu khác nhau**. Bức tranh lúc này đã rõ hơn lúc $k = 5$ và $k = 3$ khá nhiều, sắc thái của mây, trời cũng thay đổi đáng kể.

Bên cạnh đó, ta cũng không thể không nhắc tới hàm khởi tạo giá trị centroids một cách random và hàm khởi tạo giá trị centroids được tính toán trước dựa vào tham số đầu vào là ảnh X và số lớp cluster K . So với hàm đầu tiên thì hàm thứ hai có độ chính xác cao hơn, hàm đầu tiên sẽ chạy tốt hơn và cho ra kết quả nếu giá trị random gần gần với các giá trị của bức ảnh.

Mặt khác, ta cũng thấy K_means color compression chạy không được nhanh, vì nó phải quét qua toàn bộ các điểm dữ liệu nhiều lần để cập nhật điểm trung tâm. Bên cạnh đó, max_iter càng lớn thì thuật toán chạy càng lâu, nhưng sẽ khiến ảnh rõ nét hơn.

REFERENCES

[1]: <https://towardsdatascience.com/introduction-to-image-segmentation-with-k-means-clustering-83fd0a9e2fc3>

[2]: <https://towardsdatascience.com/understanding-k-means-clustering-in-machine-learning-6a6e67336aa1>

[3]: <https://machinelearningcoban.com/2017/01/01/kmeans/>